


<p>Autores: Fabiola Contreras, 22787 María José Villafuerte, 22129</p>	<p>Docente: Luis Roberto Furlán Collver</p> <p>Laboratorio 4: Clasificación de Imágenes con CNN</p>
<p>Sección: 20</p>	<p>Fecha: 21/08/2025</p>

Laboratorio 4: Clasificación de Imágenes con CNN

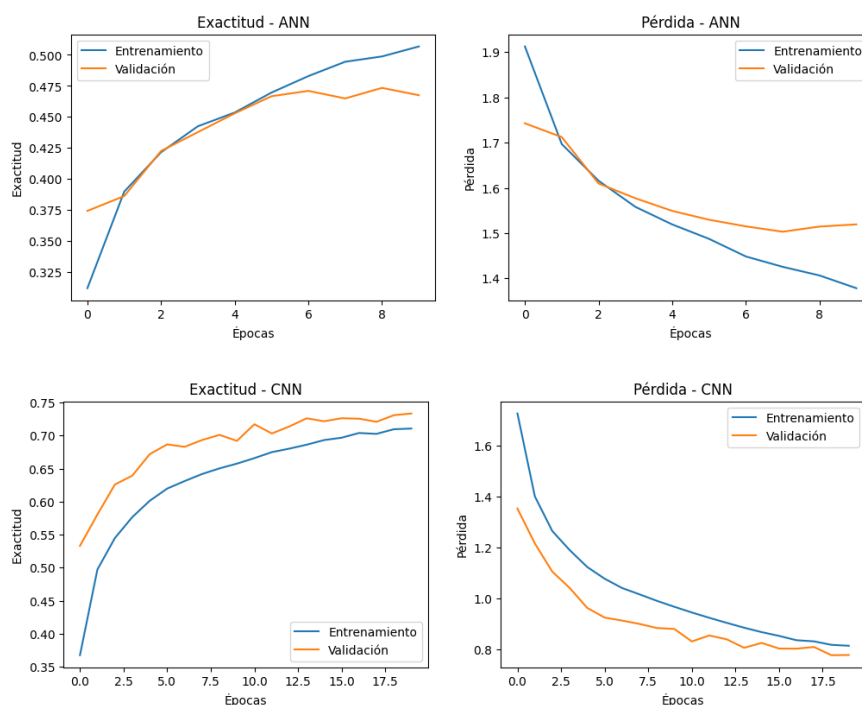
I. Jupyter Notebook


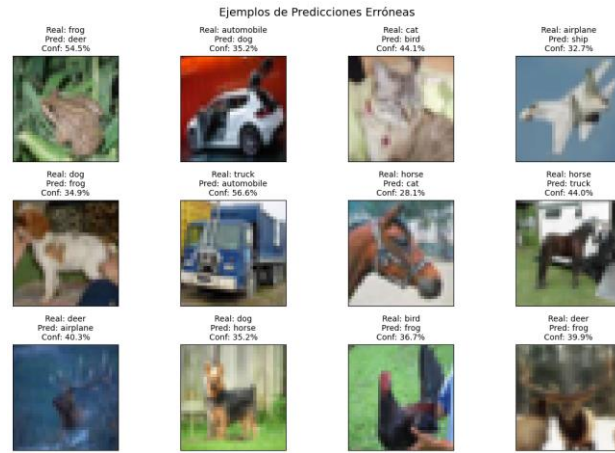

En el siguiente repositorio está el notebook con el proceso y resultados de cada paso, los invitamos a visualizarlo para comprender más a fondo lo trabajado

https://github.com/Fabiola-cc/Redes_CNN



II. Resultados





III. Reflexión

- ¿Por qué la CNN supera (o no) al modelo ANN en este problema?

La CNN supera significativamente a la ANN (71.37% vs 48.90% de exactitud) porque está específicamente diseñada para procesar datos con estructura espacial como las imágenes. Mientras que la ANN trata cada píxel de forma independiente perdiendo información espacial crucial, la CNN preserva y explota las relaciones espaciales entre píxeles vecinos. Esta capacidad de detectar patrones locales y características visuales hace que la CNN sea naturalmente superior para tareas de clasificación de imágenes.

- ¿Qué papel juegan las capas de convolución y pooling?

Las capas de convolución actúan como detectores de características que identifican patrones (bordes, texturas, formas) mediante filtros que se deslizan por la imagen, preservando la información espacial. Las capas de pooling reducen la dimensionalidad manteniendo las características más importantes, lo que proporciona invarianza a pequeñas traslaciones y reduce el costo computacional. Juntas crean una estructura de representaciones desde características simples hasta complejas, haciendo que el modelo aprenda automáticamente los patrones relevantes para la clasificación.

- ¿Qué mejoras aplicaría? (data augmentation, arquitecturas más profundas, batch normalization).

Implementaría data augmentation (rotaciones, zoom, flips) para aumentar la diversidad del dataset y reducir el overfitting visible en las gráficas de entrenamiento. Una arquitectura más profunda con más capas convolucionales permitiría aprender características más complejas y abstractas, mejorando la capacidad de generalización. Batch normalization aceleraría el entrenamiento, estabilizaría el gradiente y actuaría como regularizador, mientras que técnicas como dropout y early stopping ayudarían a controlar el sobreajuste observado en ambos modelos.